

阿尔

阿莫罗西标签

技术性蓝图 · 版本 1.0

Amorosi·HRM

确定性认知架构

一个神经符号系统将幻觉视为翻译错误，而不是统计伪影。

```
# amorosi.config 伺奉：f
```

```
alse 安全叙事：
```

```
：false
```

```
确定性：true ：
```

```
可审计：true
```

作者

胡安·P·阿莫罗西

日期

2026年2月

状态

研究中

分类

蓝图

幻觉是翻译错误

LLMs 是没有词典的翻译者：它们记住了符号之间的统计模式，却无法访问这些符号所代表的含义。

想象一个把西班牙语翻译成日语的翻译器，它从未学过这些词的意思。它只学会了相关性：当出现“casa”时，通常会出现“家”。有足够的例子，它就能产出看似正确的翻译。但你要它用海德格尔式的意义翻译“la casa del ser”，它会生成语法上成立、却在谈不动产的内容。它出现了幻觉——不是因为笨，而是因为它从未接触过含义。

PRINCIPIO FUNDACIONAL

幻觉不是需要尽量减少的 bug。这是一类需要消除的错误。解决方案不是更多参数——而是更好的语法。

形式化

设 $f: \text{Input} \rightarrow \text{Output}$ 为一个判定函数。我们要求始终存在一个可计算的验证函数：

$\forall \text{output} \in f(\text{input}) : \exists g: \text{Output} \rightarrow \text{Verificación}$ ，其中 g 可计算 $\wedge g(\text{output})$ 能追溯到知识图谱 K 中的证据

这就是 Grounding 约束：输出中的每个元素都必须有可验证的锚点。幻觉系统在不存在 g 的情况下生成在语法上成立的输出。grounded 系统保证 g 始终存在且可追溯。

✗ 幻觉系统

在不访问内容的情况下操纵形式。输出看似合理，但可能与现实毫无对应。

✓ Grounded 系统

每个符号都可追溯到有限词汇 + 证据。进行结构化验证，而非概率验证。

操作三元组

当前系统危险地混淆的三大能力。它们不应存在于同一个组件中：它们具有不可兼容的优化目标。

容量	责任	技术	自然
翻译	人机界面	大型语言模型	流畅、可适应
执行	逻辑推理	人机管理	刚性、确定性
记忆	知识定位	静态图	不可变、可审计

管道线在运行时



语义-数值同构

所有決定問題都可以映射到具有有限詞彙的空間拓撲。驗證是通過拓撲約束完成的，而不是依賴概率信任。

位置語法學 · GRID 10×10

位置編碼語义角色。值編碼原語。語义来自組合而出現。

列 0-2 · 當前狀態

列 3-5 · 變換

列 6-9 · 目標狀態

行 0-2 · 主要實體

行 3-5 · 關係

行 6-9 · 條件 / 背景

示例 · 零售定價

1	0	0	0	0
9	0	0	0	0
5	0	0	0	0
.	.	.	.	.
□	0	0	0	0

- 行 0 · 庫存 = 1 (臨界-低)
- 行 1 · 需求 = 9 (臨界-高)
- 行 2 · 競爭 = 5 (正常)
- 行 5 · 決定 = ? (待解)

HRM 實際看到的是

HRM 並不“理解”第 0 行是庫存。它看到一個空間模式：障礙(1) + 壓力(9) + 中性(5)，並產生學習到的輸出模式。

```
# 輸出
行 5 · 決定 = 12          / INC_HARD → +15% 價格上漲
```

為什麼會消除幻覺：當輸出空間被封閉且列舉時，幻想一個不存在的原語在結構上是不可能的。沒有空間去編造意義。

cartridge 模型

领域知识被封装在热插拔的 cartridge 中——如同游戏机 cartridge。一个内核，多个领域。

cartridge 的解剖结构

零售定价/
├── vocabulary.json # 原始
├── rules.yaml # 约束
└── weights.safetensors # LoRA

平面化的 cartridge

- 零售定价
- 物流路由
- 信用评分
- 医疗分诊
- 金融合规

CICLO DE VIDA DEL CARTRIDGE

阶段	过程	输出
定义	词汇+规则+业务约束	模式
编译	基于合成数据+真实数据的 GRPO 训练	LoRA 适配器
签名	所有组件的哈希密码性	签名
运行时	内核上的热交换	实时

VENTAJA ARQUITECTÓNICA

一个新领域不需要重新训练推理引擎。只需编译一个新的 cartridge。内核是不可变的；知识是模块化的。

对比预测 Cartridge

Idea2Paper 的进化

学术迭代扩展模型：cartridge 不仅包含静态知识，而且通过对未来状态的对比建模来学习预测其自身演化，在预测日志中具有加密完整性签名。适应从被动纠错转向前瞻性一致性。

GRPO & 確定性報酬

群組相對策略最佳化：使用群組的平均值作為基準。無分離的 Critic，實際梯度，對確定性報酬函數高效。

為何 GRPO 與可替代方案

方法	限制
PPO	Critic = 2× VRAM
DPO	僅勝/負，無梯度
GRPO	無 Critic，實際梯度

訓練循環

- 1. 為每個案例生成 G=16 個格子
- 2. 評估獎勵 (Rust)
- 3. 基線 = 平均獎勵
- 4. 優勢 = R - 基線
- 5. 若 adv > 0 即加強

獎勵函數 · 系統的心臟

```
def amorosi_reward(grid,      詞彙、語法、情境):
    reward = 0.0

    # 1 · 文法檢查 — 終端懲罰
    for rule in grammar.rules:
        若規則未檢查通過，返回 -5.0
    reward += 1.0

    # 2 · 詞彙檢查 — 古怪的原始用語 = 懲罰
    for cell in grid.flatten():
        若單元格不在 vocabulary.valid 中，返回 -3.0
    reward += 1.0

    # 3 · 商業邏輯 — 結果模擬 [0.0-2.0]
    reward += simulate_outcome(grid,      context)

    # 4 · 簡潔性 — 偏好簡單解決方案
    reward -= np.count_nonzero(grid)      * 0.01

    return reward
```

函數為系統的「真理」定義。用 Rust 編寫，在訓練過程中會執行數百萬次：必須快速且毫無歧義。模型探索多種解決方案並收斂到最佳解。

Cascade & 數據飛輪

所有可以離線計算的內容，應該離線計算。工廠是資本投資；商店的邊際成本接近於零。

LEVEL 0 · Rust / HRM

\$0

直接查找已預計算決策表。查詢可模式匹配。

↓ 如果不在表中

LEVEL 1 · 8B + GRPO (本地)

~\$0.001

完整管道編碼 → HRM → 解碼。覆蓋約90%的查詢。

↓ 如果信任度下降

LEVEL 2 · V3 / R1 (雲端)

~\$0.05

完整雲端推理 + 捕捉重新訓練。邊緣案例 (約10%)。

DATAFLYWHEEL

Level 2 的每個解決方案都變成 Level 1 的訓練資料。系統持續改進——今天昂貴的查詢明天就免費。

COMPARATIVA ECONÓMICA

指標	GPT-4 包裝器	AMOROSI-HRM
每次查詢成本	\$0.03-0.10	~\$0.001
延遲	5-30秒	0.5-1秒
幻覺	~15%	<0.1% *
可審計性	無	完整

* 設計目標 — 需要經實證驗證的假說，而非測得之結果

六个认知端点

API 暴露的是思维操作，而非业务领域。一个认知内核，类似于操作系统的内核。

- POST

/decide

在约束下的最优选择——定价，信贷审批
- POST

/plan

状态的时间序列化——路由，调度
- POST

/diagnose

逆向因果推断——医疗分诊，调试
- POST

/verify

约束满足度审计——合规，事实核查
- POST

/classify

本体映射——工单分类，NER
- POST

/simulate

对未来状态的投影——风险，假设推演

PROTOCOLOSANTI-ALUCINACIÓN

协议	机制	位置
受限解码	Logit bias 强制有效 tokens	编码器
语法损失	因违反拓扑而进行惩罚	GRPO
镜像检查	确定性解析器验证 Grid↔Text	后解码器
引用审计	针对图进行的已验证引用	输出

双层响应

proof_layer——可验证且持久：grid_hash、激活的 path、引用、confidence。可丢view_layer——偏视觉/装饰性且弃：可读决策、解释。证明从不依赖叙述。

从赫梯人到张量的演变

赫梯人将苏美尔楔形文字改编，同时在文化之间保持意义。它们翻译形式同时保留功能。胡安的父亲，语言学家，研究符号如何迁移以及语法如何演化。这个项目在另一种基质中也是相同的。

知识产权

汉斯·乌斯科莱特（语言学家）
→ 雅各布·乌斯科莱特（Transformer）
→ 注意力 = 符号之间的关系

阿莫罗西父亲（历史学家）
→ 胡安·阿莫罗西（grounding）
→ 与可验证意义的锚定

舞者

齿轮只是数字。舞者只是解释。魔力在于两者同时成立。

现实状态与证据性证据（基于经验的）

✓ 已完成

- 基础文档 v0.1
- 蓝图 v1.0
- GRPO 机制已指定
- 定义的奖励函数
- API 规范 · 6 个端点
- 白皮书 Idea2Paper

○待处理

- 可执行最小可行产品
- 10k 个合成案例
- 训练 GRPO 适配器
- 集成 Sapient HRM
- 测量实际 GTCR
- 经验验证

POSICIÓN HONESTA

Amorosi-HRM 是一个雄心勃勃的架构假设，正在积极开发中——不是一个经过验证的系统。度量标准是设计目标，而不是测量结果。这种诚实是优势，而不是弱点。

阿尔

阿莫罗西拉布斯

“将决策锚定在可验证的结构上。”

DETERMINISTIC · 可 审计 · 主权

Amorosi Labs © 2026 · Bahía Blanca, 阿根廷