

内核之前

Amorosi-HRM 的人文基石

从赫梯人到可验证意义的架构。

```
# foundations.config

nostalgia: false

mythology: constrained

meaning: anchored

epistemic_honesty: true
```

作者	Juan P. Amorosi
日期	2026年7月
状态	研究中
分类	基础说明

《Amorosi-HRM Technical Blueprint v1.0》的配套文档。它不描述机制本身，而解释机制为何存在。

理论之前的那一幕

在模型之前，先有一张桌子、一次搜索，以及一句承诺。

远在网格、张量和各种模型名称出现之前，有过一个很普通的家庭场景：父亲和儿子一起查找关于赫梯人的资料。就在那次搜索中，父亲说了一句话，多年以后仍然悬在那里：“有一天，你会用计算机做出一件很大的事。”

我并不把它记作某种技术预言。我把它记作一次信任的转移。父亲以历史研究者的眼光看语言：符号如何迁徙，一种文化如何继承另一种文化的形式，语法如何保存某些东西，又如何扭曲另一些东西。而我看着屏幕。我们之间其实已经存在一个我当时还不会表达的问题。

意义如何从一个系统跨越到另一个系统，而不在途中破裂？

赫梯人在这里与其说是某种架构的历史证明，不如说是这个问题最早的一幅图像。符号可以迁移，形式可以比创造它的人活得更久。但保存形式，并不等于保存功能。符号与意义之间始终存在一条危险的边界：翻译。

Amorosi-HRM 并不是从这个问题的答案中诞生的，而是从无法把这个问题放下中诞生的。多年以后，当我们面对能够生成惊人语言、却也能流畅断言不存在之物的系统时，那一幕又回来了。问题看似全新，伤口却很古老。

本文从这里开始。不是从 API，不是从 HRM，也不是从 Rust。它从一种怀疑开始：可靠的智能不能只生产令人信服的符号；它还必须证明，意义在翻译之后仍然活着。

点与关系

在我知道什么是张量之前，已经有一种更简单的直觉：点。

一个孤立的点几乎什么也不说。两个点引入距离。三个点可能暗示形状。很多点，如果占据精确的位置，就会成为地图、星座、电路或文字。意义的出现，并不是因为一个点内部藏着秘密思想，而是因为一种关系稳定了下来。

这种童年的直觉，今天以技术名称重新出现：嵌入、注意力、拓扑、状态、图。但核心仍然异常人类化。一事物之所以意味着某物，也因为它在哪里、与什么相连、能够触碰什么，以及被禁止触碰什么。

现代语言模型把这种能力推到了惊人的尺度。它们学习符号之间的关系，精度曾经近乎科幻。然而，关系还不是锚定。一个系统可以发现两个表达经常共同出现，却没有机制迫使这种关系对应某个实体、规则或外部证据。

这正是本项目核心执念出现的地方：如果关系能够产生结构，我们能否设计一种结构，使某些关系不只是“更可能”，而是“有效”或“无效”？

问题的重心随之改变。目标不再只是训练机器选择下一个看似合理的词，而是构造一种空间，让决策必须“卡得进去”。让原语拥有位置，让组合拥有语法，让输出留下痕迹。

“点”并不是网格的装饰性比喻。它们是一个更硬核命题的直觉祖先：只要系统知道自己的边界，意义就可能通过显式关系被保存。

技术蓝图会把这种直觉变成有限词汇、约束、拓扑和分层。但在机制之前，先有这幅图像：那些终于不再漂浮的点。

没有词典的翻译者

生成式 AI 制造了一个历史性的悖论：机器从未如此流利；人类也从未如此容易把流利误认为保证。

想象一个翻译者，掌握西班牙语与日语之间数百万种相关性，却没有一本词典迫使语言触碰意义。它可以非常惊艳。它也可以把一句哲学表达翻译成房地产描述，而且语法完美。错误听起来不像错误——这才是问题。

Amorosi-HRM 的命题，是把“幻觉”视为一种不忠实的翻译。它并不声称穷尽 LLM 幻觉的全部成因，也不宣称概率毫无价值。它提出的是一个更窄、更可操作的原则：当输出要支撑决策时，流利不能拥有最后裁决权。

一个决策系统需要分开两个今天常被混在一起的问题：“听起来对吗？”以及“我们能重建为什么它有效吗？”。前者属于语言，后者属于结构。

因此，这套架构并不试图消灭概率组件，而是限制它。语言可以在边缘保持灵活——接住人类的歧义，再返回可读解释——但这种灵活性不能在核心中拥有最终权威。

这是一种权力分立：流动的翻译、刚性的执行、可审计的记忆。

这种做法不如“通用人工心智”的承诺耀眼，却可能更有用。它不问如何让机器“什么都知道”，而问：当系统无法在允许的空间内证明一个决策时，能否有纪律地停下、升级，或者承认不知道。

可靠性，始于不再被迫显得聪明。

钟表与舞者

机械钟里有很多齿轮。没有任何一个齿轮“知道时间”。时间不藏在某个零件里；它从有限零件、精确关系与共享解释的稳定组合中涌现出来。

这幅图像提供了一条理解 AI 的道路：少一点魔法，多一点可验证。如果每个组件什么都能做，表达力会增长，错误空间也会增长。如果每个组件有角色、有词汇、有组合规则，系统会失去部分自由，却获得可证明性。

有限词汇。不是每个符号都合法。

显式语法。不是每种组合都有效。

定义好的解释。输出必须能够回到它的意义与证据。

在 Amorosí-HRM 的技术文档中，这种直觉被具体化为网格、原语、cartridge、规则、哈希和证明层。但这些对象并不是起点。它们只是试图把一个更早的想法变成材料：意义不只取决于零件，也取决于“咬合”。

然后，舞者出现了。

大齿轮可以是状态与变换，中齿轮可以是组织关系的语法，小齿轮可以是允许解释的原语。任何一个单独存在，都不包含人的决策。然而，如果系统保存数字、位置、约束与证据之间的对应关系，就可能涌现出我们能够识别为“决策”的东西。

齿轮只是数字。舞者只是解释。真正的魔法，是两者可以同时成立。

这不是对机械的浪漫化。它只是提醒我们：没有机制的解释会发明；没有解释的机制即使正确，也可能对任何人都毫无意义。

给概率画出边界

蓝图从本文停止讲述传记、开始成为架构的地方起步。它最核心的决定，说起来简单，执行起来困难：流动的、刚性的、持久的，不能混为一谈。

自然语言开放、含混、变化。约束逻辑需要精确。支撑决策的记忆需要可追溯。要求同一个组件同时优化三者，就像要求它在同一次呼吸里成为诗人、法官和档案馆。

因此，Amorosi-HRM 提出语义边缘与结构核心。边缘处，接口解释人类的混沌；中心处，受限空间变换状态；最后，另一个接口重新开口。但证明不依赖最终的叙事。

这一区分改变了“减少幻觉”的含义。它不是声称任何概率组件都不会再出错，而是设计成：解释错误不能悄无声息地变成权威。系统需要验证、拒绝、记录、升级，并保存一条可重建的路径。

概率可以提议。结构必须裁决。

HRM、有限词汇、确定性 reward、cartridge 与级联推理，都是为这条边界服务的技术假设。有些也许会按当前形式成立，有些必须改变。连接它们的原则比任何实现更稳定：高影响决策不应只依赖一串令人信服的 token。

这就是从赫梯人的那一幕走向 kernel 的过渡。同一个问题，换了一个载体：当一种表示跨越两个世界时，什么机制能够保存意义？

实用真理，而不是神谕

“真理”在技术领域是一个危险的词。它诱惑人做绝对承诺，而绝对承诺往往正是 AI 项目的第一场幻觉。

因此，在这项研究中，实用真理并不意味着形而上学的终极真理，也不意味着普遍无误。它指向一种更谦逊、却更严格的操作属性：一个决策能够从输入、允许的变换、约束、证据与持久化证明中被重新构建。

即使系统可审计，输出仍可能错误：数据可能不完整，词汇可能贫乏，规则可能错误表达领域。区别在于，错误拥有解剖结构。它可以被定位、反驳、修正，而不需要假装它从未发生。

这里真正关心的“主权”也是这种主权。不是浪漫地脱离所有外部基础设施，而是能够知道：一个决策的哪一部分来自模型，哪一部分来自规则，哪一部分来自数据，哪一部分只是叙述。

证明层与展示层不是同一件事。展示可以优雅、共情、可丢弃；证明必须持久、可验证，并抵抗语言魅力。

这种立场也要求一种不舒服的诚实：Amorosi-HRM 仍是一个处于主动研究中的架构假设。MVP、GRPO 训练、HRM 集成以及真实指标，都还需要验证或推翻核心部分。凡是尚未测量的延迟、成本与幻觉数据，都只能被称为设计目标。

这不是文案上的弱点，而是方法的一部分。一个声称要把决策锚定到可验证结构的系统，不能从谎报自身状态开始。

机器的第一份证明，是实验室的诚实。

门槛

本文不是蓝图。它是蓝图试图站立的地面。

接下来的技术文档会谈谈到操作三元组、语义-数值同构、网格、cartridge、GRPO、reward、级联、认知端点与反幻觉协议。这些部件很重要。但如果没有先于它们的人类问题，它们很容易退化为另一套流行组件集合。

那个问题更古老，也更简单：

我们怎样让一个符号抵达另一端，而不失去它本来应该保存的东西？

一位父亲和一个儿子曾在电脑上寻找古代文明。多年以后，儿子试图构造一种系统，让决策无法躲在漂亮句子背后。这两幕之间没有直线，也没有“预言实现”。只有一种执念改变了尺度。

赫梯人提供了传递的图像。点，提供了关系的直觉。语言模型，展示了形式可以走多远。幻觉提醒我们，形式仍然不够。钟表给出组合的直觉。舞者给出解释的直觉。

Amorosi-HRM 目前只是试图把这些部件装配起来，同时拒绝假装装配已经被证明。

目标不是制造一个永不怀疑的神谕。

目标是制造一台知道叙事在哪里结束、证明在哪里开始的机器。

本文在这里结束。

kernel 从这里开始。

ANCHOR DECISIONS TO VERIFIABLE STRUCTURE.